

Tokemize

Otimização de Contexto para LLMs

! O Problema

Agentes de IA recebem contexto demais e sem critério, prejudicando o desenvolvimento de software moderno.

☢ Consequências

- **Alto custo** de tokens.
- **Respostas imprecisas** e alucinações.
- **Processamento ineficiente**.

🧠 A Ideia

Um agente inteligente que decide exatamente o que deve ser enviado ao LLM, otimizando cada requisição técnica.

"Mais contexto não significa melhor resposta."



Entrada Bruta



Tokemize



Entrada Otimizada

Arquitetura da Solução

Usuário



Tokenize



Seleção



Resumo



Otimização



LLM



Componentes do Sistema

Análise de Repositório

Mapeamento completo da estrutura de código.

Seleção Inteligente

Filtro de relevância baseado em contexto técnico.

Compressão e Resumo

Redução semântica do volume de dados.

Cache de Contexto

Eficiência máxima em consultas repetitivas.

</> Tecnologias



Python (Orquestração Principal)



Tree-sitter (Análise Sintática)



FAISS (Indexação Vetorial)



APIs de LLM (OpenAI / Anthropic)

<https://docs.python.org/3/> / <https://tree-sitter.github.io/tree-sitter/> / <https://faiss.ai/index.html> /
<https://console.groq.com/docs/overview>

"Uma camada intermediária que melhora como usamos IA."